

INFERÊNCIA ESTATÍSTICA CONCEITOS INTERMEDIÁRIOS (Unidade 2)

INFERÊNCIA ESTATÍSTICA (CONCEITOS INTERMEDIÁRIOS)

ESTATÍSTICA SUFICIENTE

Instituto de Educação Superior de Brasília
A Teoria e a Prática Juntas



- Uma estatística $T=T(Y)$ é suficiente para um parâmetro θ quando resume toda informação sobre esse parâmetro contida na amostra Y . Se T é suficiente para θ , então, a distribuição condicional Y dada a estatística $T(Y)$ é independente de θ , isto é:

$$P(\mathbf{Y} = \mathbf{y} | T = t, \theta) = P(\mathbf{Y} = \mathbf{y} | T = t).$$

- Ou seja, se X e Y são duas amostras tais que $T(x)=T(y)$, então a inferência sobre θ é a mesma independente da observação X ou Y .

INFERÊNCIA ESTATÍSTICA (CONCEITOS INTERMEDIÁRIOS)

CRITÉRIO DA FATORAÇÃO E ESTATÍSTICAS CONJUNTAMENTE SUFICIENTES

Instituto de Educação Superior de Brasília
A Teoria e a Prática Juntas



- O critério da fatoração é uma forma conveniente de caracterizar uma estatística suficiente. Uma condição necessária e suficiente para T ser suficiente para um parâmetro θ é que a função (densidade ou de probabilidade) $f_Y(y; \theta)$ possa ser decomposta como

$$f_Y(y; \theta) = h(y)g(t, \theta),$$

- Em que $t=T(y)$ e $h(y)$ não dependem de θ . Esse resultado é válido para o caso contínuo e discreto.
- O conceito de estatística suficiente é importante em estatística no sentido de se poder concentrar a informação sobre o parâmetro. Formalmente tem: se Y_1, Y_2, \dots, Y_n é uma amostra de uma densidade $f(y; \theta)$, em que θ é um vetor de parâmetros, as estatísticas S_1, S_2, \dots, S_r são conjuntamente suficientes se, e somente se, a distribuição conjunta de Y_1, Y_2, \dots, Y_n , dadas $S_1 = s_1, S_2 = s_2, \dots, S_r = s_r$ não depende de θ .

- Família exponencial de distribuições: conjunto de distribuições conhecidas inseridas em uma família paramétrica.
- Exemplos de distribuições:
 - Normal;
 - Binomial;
 - Binomial Negativa;
 - Gama;
 - Poisson;
 - Normal Inversa;
 - Multinomial;
 - Beta;
 - Logarítmica, etc.
- A importância da família exponencial de distribuições teve maior destaque, na área dos modelos de regressão, a partir do trabalho pioneiro de Nelder e Wedderburn (1972) que definiram os modelos lineares generalizados (MLG). Na teoria da

Inferência Estatística auxilia nas diversas demonstrações das propriedades dos estimadores.

INFERÊNCIA ESTATÍSTICA (CONCEITOS INTERMEDIÁRIOS)

FAMÍLIA EXPONENCIAL UNIPARAMÉTRICA

Instituto de Educação Superior de Brasília
A Teoria e a Prática Juntas



- A família exponencial uniparamétrica é caracterizada por uma função (de probabilidade ou densidade) da seguinte forma:

$$f(x; \theta) = h(x) \exp [\eta(\theta) t(x) - b(\theta)]. \quad (1.1)$$

onde: $\eta(\theta)$, $b(\theta)$, $t(x)$ e $h(x)$ pertencem aos subconjuntos dos reais.

- Diversas distribuições conhecidas e importantes podem ser estruturadas de acordo com a função supra. Exemplos:
 - Distribuição de Poisson
 - Distribuição Binomial
 - Distribuição Normal

INFERÊNCIA ESTATÍSTICA (CONCEITOS INTERMEDIÁRIOS)

FAMÍLIA EXPONENCIAL UNIPARAMÉTRICA

Instituto de Educação Superior de Brasília
A Teoria e a Prática Juntas



- Exemplo da distribuição de Poisson:

A distribuição de Poisson $P(\theta)$ de parâmetro $\theta > 0$, usada para análise de dados na forma de contagens, tem função de probabilidade

$$f(x; \theta) = \frac{e^{-\theta} \theta^x}{x!} = \frac{1}{x!} \exp[x \log(\theta) - \theta]$$

e, portanto, é um membro da família exponencial (1.1) com $\eta(\theta) = \log(\theta)$, $b(\theta) = \theta$, $t(x) = x$ e $h(x) = 1/x!$.

INFERÊNCIA ESTATÍSTICA (CONCEITOS INTERMEDIÁRIOS)

FAMÍLIA EXPONENCIAL MULTIPARAMÉTRICA

Instituto de Educação Superior de Brasília
A Teoria e a Prática Juntas



- A família exponencial multiparamétrica de dimensão k é caracterizada por uma função (de probabilidade ou densidade) da forma

$$f(\mathbf{x}; \boldsymbol{\theta}) = h(\mathbf{x}) \exp \left[\sum_{i=1}^k \eta_i(\boldsymbol{\theta}) t_i(\mathbf{x}) - b(\boldsymbol{\theta}) \right] \text{ equivalente à } f(\mathbf{x}; \boldsymbol{\theta}) = h(\mathbf{x}) \exp \left[\sum_{i=1}^k \theta_i t_i(\mathbf{x}) - b(\boldsymbol{\theta}) \right]$$

em que θ é um vetor de parâmetros, usualmente, de dimensão k , e as funções $\eta_i(\theta)$, $b(\theta)$, $t_i(\mathbf{x})$ e $h(\mathbf{x})$ têm valores em subconjuntos dos reais.

- A forma abaixo é um caso especial:

$$f(x; \theta) = h(x) \exp [\eta(\theta) t(x) - b(\theta)]:$$

- Diversas distribuições conhecidas são pertencentes à família exponencial multiparamétrica, dentre elas: Normal, Gama Beta, Weibull e Multinomial.

INFERÊNCIA ESTATÍSTICA (CONCEITOS INTERMEDIÁRIOS)

MÉTODO DE MÁXIMA VEROSSIMILHANÇA

Instituto de Educação Superior de Brasília
A Teoria e a Prática Juntas



- Definição: a obtenção de estimadores pelo método conhecido por Máxima Verossimilhança (M.V) parte do princípio de que devemos escolher o(s) valor(es) do(s) parâmetro(s) desconhecido(s) que maximiza a probabilidade de obter a amostra particular observada, ou seja, o(s) valor(es) do(s) parâmetro(s) que torna aquela amostra a “mais provável”.
- Exemplo: consideremos a função de probabilidade de uma v.a. Binomial a qual é dada por

$$p(x) = \binom{n}{x} p^x (1-p)^{n-x}, \quad x = 0, 1, \dots, n.$$

Quando nós passamos a observar esta função não como dependente da amostra x (total de sucessos) mas sim como função do parâmetro p , temos o que denominamos função de verossimilhança, $L(p)$, a qual deve ser maximizada para assim obtermos o estimador de máxima verossimilhança. Em geral, e por facilidade, nós maximizamos a log-verossimilhança a qual é o logaritmo neperiano da função de verossimilhança denotada por $l(p) = \ln L(p)$.

INFERÊNCIA ESTATÍSTICA (CONCEITOS INTERMEDIÁRIOS)

MÉTODO DE MÁXIMA VEROSSIMILHANÇA

Instituto de Educação Superior de Brasília
A Teoria e a Prática Juntas



- Seja (X_1, X_2, \dots, X_n) uma amostra aleatória da variável aleatória $X \sim \text{Poisson}(\theta)$, $\theta > 0$. Encontre o Estimador de Máxima Verossimilhança (E.M.V.) de θ .

Nesse caso a função de verossimilhança é dada por

$$L(\theta|x) = \prod_{i=1}^n f(x_i, \dots, x_n|\theta) = \prod_{i=1}^n \frac{\theta^{x_i} e^{-\theta}}{x_i!} = \frac{\theta^{\sum x_i} e^{-n\theta}}{\prod x_i!}$$

O logaritmos da função de verossimilhança é dado por:

$$l(\theta|x) = -n\theta + \sum_{i=1}^n x_i \ln(\theta) - \sum_{i=1}^n \ln x_i!$$

INFERÊNCIA ESTATÍSTICA (CONCEITOS INTERMEDIÁRIOS)

MÉTODO DE MÁXIMA VEROSSIMILHANÇA

Instituto de Educação Superior de Brasília
A Teoria e a Prática Juntas



O estimador de máxima verossimilhança é obtido aplicando a 1ª derivada e igualando a 0 (zero). Isto é:

$$l(\theta|x) = -n + \frac{\sum_{i=1}^n x_i}{\hat{\theta}} = 0 \rightarrow \hat{\theta} = \bar{x}$$

Agora é preciso verificar se o resultado encontrado é um ponto de máximo:

$$\frac{d^2 l(\theta|x)}{d\theta^2} = \frac{-\sum_{i=1}^n x_i}{\hat{\theta}^2} : \theta = \bar{x} < 0$$

Logo, $\hat{\theta} = \bar{x}$ é um EMV.

INFERÊNCIA ESTATÍSTICA (CONCEITOS INTERMEDIÁRIOS)

MÉTODO DOS MOMENTOS

Instituto de Educação Superior de Brasília
A Teoria e a Prática Juntas



- Seja uma a.a. $X' = [X_1, X_2, \dots, X_n]$ de uma população com f.p. ou f.d.p. dependendo de k parâmetros $\theta_1, \theta_2, \dots, \theta_k$. Os momentos ordinários da população $m_j = \int_{-\infty}^{\infty} x^j f(x, \theta_1, \dots, \theta_k) dx$, se existirem, são funções dos k parâmetros $m_j = f(\theta_1, \theta_2, \dots, \theta_k)$, $j = 1, 2, 3, \dots$. Considere, também, os momentos ordinários da amostra, $M_j = \frac{\sum x^j}{n}$, $j = 1, 2, 3, \dots$, forme o sistema de equações:

$$M_j = m_j = f(\theta_1, \theta_2, \dots, \theta_k), j = 1, 2, 3, \dots$$

e admita que tem solução única, $\hat{\theta}_j(X_1, X_2, \dots, X_n)$, $j = 1, 2, 3, \dots, k$. Então, estes k estimadores, solução do sistema de equações, são os estimadores dos parâmetros pelo Método dos Momentos.

Os estimadores obtidos pelo Método dos Momentos são em geral consistentes e possuem distribuição assintótica Gaussiana, porém não são assintoticamente mais eficientes do que os estimadores de máxima verossimilhança.

- Seja $[X_1, X_2, \dots, X_n]$ uma a.a. da densidade $f(., \theta)$, e seja $S_1 = s_1(X)$, $S_2 = s_2(X)$, \dots , $S_k = s_k(X)$ um conjunto de estatísticas conjuntamente suficientes. Seja a estatística $T = t(X)$ um estimador não-viciado de $q(\theta)$. Defina T' por $T' = E[T | S_1, S_2, \dots, S_k]$, então:
 - T' é uma estatística e é uma função de estatísticas suficientes S_1, S_2, \dots, S_k ;
 - $E_\theta[T'] = q(\theta)$, isto é T' é um estimador não-viciado de $q(\theta)$;
 - $V_\theta[T'] \leq V(T)$ qualquer que seja θ e $V_\theta[T'] < V(T)$ para algum θ a menos que T seja igual a T' com probabilidade 1.

- Se $T(X)$ é uma estatística suficiente e completa e $S(X)$ é um estimador não-viciado de $q(\theta)$, então $T^*(X) = E[S(X) | T(X)]$ é um estimador UMVU de $q(\theta)$. Se $V_{\theta}(T^*(X)) < \infty$ qualquer que seja θ , $T^*(X)$ é o único estimador UMVU de $q(\theta)$.
- Podemos usar o Teorema de Lehmann-Scheffé na busca de estimadores UMVU de dois modos:
 - Se nós podemos achar uma estatística da forma $h[T(X)]$ tal que $h[T(X)]$ seja um estimador não-viciado de $q(\theta)$, então $h[T(X)]$ é UMVU para $q(\theta)$.
 - Se nós podemos achar algum estimador não-viciado $S(X)$ de $q(\theta)$, então $E[S(X) | T(X)]$ é UMVU para $q(\theta)$.

UMVU: ESTIMADORES NÃO-VICIADOS UNIFORMEMENTE DE MÍNIMA VARIÂNCIA.

INFERÊNCIA ESTATÍSTICA (CONCEITOS INTERMEDIÁRIOS)

EXERCÍCIO

Instituto de Educação Superior de Brasília
A Teoria e a Prática Juntas



LISTA DE EXERCÍCIOS 1 – parte II

Data limite de entrega: vide cronograma em “Sistema de avaliação”